Документация проекта ETL-пайплайна

Общая архитектура

Проект реализует ETL-пайплайн для загрузки данных из MongoDB в PostgreSQL с последующей трансформацией и подготовкой данных для аналитики.

MongoDB → raw schema → transformed schema → mart schema.

Состав DAG-ов

1. mongo_to_postgres_raw

Назначение: Первичная загрузка данных из MongoDB в PostgreSQL
Расписание: Каждые 15 минут.
Загружаемые коллекции:

- supportTickets → raw.support_tickets
- eventLogs → raw.event_logs
- userSessions → raw.user_sessions
- moderationQueue → raw.moderation_queue
- userRecommendations → raw.user_recommendations

Логика: Сохраняет сырые JSON-документы с MongoDB_id в качестве ключа.
Триггер: После успешного выполнения запускает raw_to_transformed.

2. raw_to_transformed

Назначение: Трансформация сырых JSON-данных в структурированные таблицы.
Расписание: Каждые 30 минут.
Выполняет:

- Извлечение вложенных полей из JSON
- Преобразование MongoDB timestamp в PostgreSQL timestamp
- Разворачивание массивов в строки
- Создание связей между таблицами

Трансформации:

- support_tickets → transformed_support_tickets (основная информация)
- support_tickets.messages → transformed_ticket_messages (сообщения)
- event_logs → transformed_event_logs (события с раскрытием details)
- user_sessions → transformed_user_sessions (сессии с действиями и страницами)
- moderation_queue → transformed_moderation_queue (очередь модерации)

- user_recommendations → transformed_user_recommendations (рекомендации)
-

Триггеры: После успешного выполнения запускает:
- load_mart_sessions
- load_support_tickets_analytics

3. load_mart_sessions

Назначение: Подготовка данных для аналитики по пользовательским сессиям
Схема: mart
Таблицы:
- user_sessions_main - основная информация о сессиях
  - session_uuid (ключ)
  - user_id, device, start_time, end_time, duration_seconds
- user_session_details - детали сессий
  - session_id, detail_type ('action'/'page'), detail_value

Загрузка: Полная перезагрузка (TRUNCATE + INSERT)

4. load_support_tickets_analytics

Назначение: Подготовка аналитических данных по тикетам поддержки
Схема: mart
Таблица: support_tickets_analytics
Поля:
- ticket_id (mongo_id) - первичный ключ
- status - статус тикета
- issue_type - тип проблемы
- resolve_duration - время решения (INTERVAL) для закрытых тикетов

Схема данных

raw schema

Хранит сырые JSON-данные с MongoDB:

- raw.support_tickets
- raw.event_logs
- raw.user_sessions
- raw.moderation_queue
- raw.user_recommendations

transformed schema

Структурированный данные после трансформации:

- raw.transformed_support_tickets
- raw.transformed_ticket_messages
- raw.transformed_event_logs
- raw.transformed_user_sessions
- raw.transformed_moderation_queue
- raw.transformed_user_recommendations

mart schema

Готовые аналитические таблицы:

- mart.user_sessions_main
- mart.user_session_details
- mart.support_tickets_analytics

Запросы к mart-таблицам

```
select *
from mart.user_sessions_main
```

sessions_main 1

Enter a SQL expression to filter results (use Ctrl+Space)

session_uuid	user_id	device	start_time	end_time	duration_seconds
69ad65326d32508fa63f118c	user_123	mobile	2024-01-10 09:00:00.000	2024-01-10 09:30:00.000	1,800
69ad65326d32508fa63f118d	user_456	desktop	2024-01-10 10:15:00.000	2024-01-10 10:45:00.000	1,800
69ad65326d32508fa63f118e	user_789	tablet	2024-01-10 11:30:00.000	2024-01-10 12:00:00.000	1,800

```sql
select *
from mart.support_tickets_analytics
```

rt_tickets_analytics 1

* from mart.support_tickets_analytics | Enter a SQL expression to filter results (use Ctrl+Space)

ticket_id	status	issue_type	resolve_duration
69ad65326d32508fa63f1193	open	payment	[NULL]
69ad65326d32508fa63f1194	resolved	delivery	01:00:00
69ad65326d32508fa63f1195	in_progress	technical	[NULL]

```sql
select *
from mart.user_session_details
```

er_session_details 1

ect * from mart.user_session_details | Enter a SQL expression to filter results (use Ctrl+Space)

id	session_uuid	detail_type	detail_value
217	69ad65326d32508fa63f118c	action	login
219	69ad65326d32508fa63f118c	action	view_product
220	69ad65326d32508fa63f118c	action	add_to_cart
221	69ad65326d32508fa63f118c	action	logout
222	69ad65326d32508fa63f118d	action	login
223	69ad65326d32508fa63f118d	action	search
224	69ad65326d32508fa63f118d	action	view_product
225	69ad65326d32508fa63f118d	action	purchase
226	69ad65326d32508fa63f118e	action	login
227	69ad65326d32508fa63f118e	action	view_profile
228	69ad65326d32508fa63f118e	action	update_settings
229	69ad65326d32508fa63f118e	action	open_support_chat
218	69ad65326d32508fa63f118c	page	/home